

외향인들 사이에서 내향인 예측하기

데이터사이언스전공
202404185 구은완
202404252 원종우

목 차

01

주제 개요

02

데이터구조

03

진행과정

04

주요코드


05

분석결과

06

결론

꾸찌 개요



데이터 구조

```
train.head()
```

✓ 0.0s

	id	Time_spent_Alone	Stage_fear	Social_event_attendance	Going_outside	Drained_after_socializing	Friends_circle_size	Post_frequency	Personality
0	0	0.0	0.0	6.0	4.0	0.0	15.0	5.0	0
1	1	1.0	0.0	7.0	3.0	0.0	10.0	8.0	0
2	2	6.0	1.0	1.0	0.0	NaN	3.0	0.0	1
3	3	3.0	0.0	7.0	3.0	0.0	11.0	5.0	0
4	4	1.0	0.0	4.0	4.0	0.0	13.0	NaN	0

```
test.head()
```

✓ 0.0s

	id	Time_spent_Alone	Stage_fear	Social_event_attendance	Going_outside	Drained_after_socializing	Friends_circle_size	Post_frequency
0	18524	3.0	0.0	7.0	4.0	0.0	6.0	NaN
1	18525	NaN	1.0	0.0	0.0	1.0	5.0	1.0
2	18526	3.0	0.0	5.0	6.0	0.0	15.0	9.0
3	18527	3.0	0.0	4.0	4.0	0.0	5.0	6.0
4	18528	9.0	1.0	1.0	2.0	1.0	1.0	1.0

진행과정

데이터 분석

Pandas를 활용하여 결
측치 확인 및 칼럼 확인

모델 제작

랜덤포레스트 분류모델
제작

파라미터 튜닝

n_estimators,
max_depth,
GridSearchCV

결론 도출

최종분류 결과 파일 저
장, 시각화

주요코드

(범주형 인코딩)

```
# 2. 범주형 인코딩 (Yes/No → 0/1)
binary_cols = ["Stage_fear", "Drained_after_socializing"]

for col in binary_cols:
    train[col] = train[col].map({"No": 0, "Yes": 1})
    test[col] = test[col].map({"No": 0, "Yes": 1})
```

✓ 0.0s

주요코드

(랜덤포레스트 모델 학습 & 예측)

```
model = RandomForestClassifier(  
    n_estimators=300,  
    max_depth=10,  
    random_state=42  
)
```

```
model.fit(X, y)
```

✓ 3.4s

▼ RandomForestClassifier ⓘ ?

▶ Parameters

RandomForestClassifier

- 여러 개의 의사결정나무를 생성하여 투표 방식으로 최종 예측을 수행하는 ensemble 모델.

n_estimators=300

- 300개의 트리를 사용하여 예측 안정성 증가.

max_depth=10

- 과적합 방지를 위한 트리 깊이 제한.

random_state=42

- 재현 가능한 결과를 위해 랜덤 시드 고정.


목적: 안정적이고 과적합을 줄인 성능 좋은 모델 구축

기존 랜덤포레스트 문제점

n_estimators

max_depth

min_samples_split





데이터

=

overfitting

GridSearchCV 소개



가능한 모든 파라미터 조합을 탐색하고,
교차검증(Cross Validation)을 통해 가장 좋은 성능을 내는 조합을 자동으로 찾아줌.

GridSearchCV 결과

```
from sklearn.model_selection import GridSearchCV

param_grid = {
    'n_estimators': [100, 300, 500],
    'max_depth': [5, 10, 15],
    'min_samples_split': [2, 5]
}

grid = GridSearchCV(
    RandomForestClassifier(random_state=42),
    param_grid,
    cv=3,
    scoring='accuracy',
    n_jobs=-1
)


grid.fit(X_train, y_train)
```

```
print("Best Params:", grid.best_params_) Best Params: {'max_depth': 5, 'min_samples_split': 2, 'n_estimators': 300}
print("Best CV Score:", grid.best_score_) Best CV Score: 0.9688914883030462
```

max_depth: 5
min_samples_split: 2
n_estimators: 300
bestcv점수: 0.968

시각화 결과

(외향/내향을 결정하는 핵심 요인)



결론

```
id,Personality
18524,Extrovert
18525,Introvert
18526,Extrovert
18527,Extrovert
18528,Introvert
18529,Extrovert
18530,Extrovert
18531,Introvert
18532,Extrovert
18533,Introvert
18534,Extrovert
18535,Extrovert
18536,Introvert
18537,Extrovert
```

Submissions

You selected 0 of 2 submissions to be evaluated for your final leaderboard score. Since you selected less than 2 submissions, Kaggle auto-selected up to 2 submissions from among your public best-scoring unselected submissions for evaluation. The evaluated submission with the best Private Score is used for your final score.

☒ Submissions evaluated for final score

All

Successful

Selected

Errors

Recent ▼

Submission and Description	Private Score ⓘ	Public Score ⓘ	Selected
 submission.csv Complete (after deadline) · 1h ago	0.968016	0.973279	☐

총 6176개의 데이터 분류 완료
캐글 점수 0.96대

감사합니다

프로젝트에 사용된 소스코드와 데이터는 아래 qr코드를 통해 확인하실 수 있습니다

